

UnespDataLens

Framework de Engenharia de Dados Analíticos com Governança, Qualidade, Proveniência e Reprodutibilidade

O **UnespDataLens** é um **framework técnico-metodológico de Engenharia de Dados Analíticos** voltado à transformação de dados heterogêneos, distribuídos, pouco documentados e de múltiplas naturezas em **ativos analíticos confiáveis, qualificados, governados, rastreáveis, versionados, reutilizáveis e adequados ao uso**.

O framework organiza conceitos, módulos, processos, métodos, técnicas, métricas e artefatos necessários para estruturar pipelines completos de dados, desde a identificação das fontes até a disponibilização de produtos analíticos para análise, visualização, modelagem, inteligência artificial, grafos, indicadores e tomada de decisão baseada em evidências.

Esta wiki foi criada para apoiar o estudo, a pesquisa, a implementação e a evolução do UnespDataLens. Cada página contém links para conceitos, métodos, técnicas, problemas, artefatos, métricas e exemplos de aplicação.

1. Como navegar nesta wiki

A wiki do **UnespDataLens** está organizada em seis grandes áreas de navegação:

1. [\[\[Visão Geral do UnespDataLens\]\]](#)
2. [\[\[Módulos do Framework\]\]](#)
3. [\[\[Dimensões Complementares\]\]](#)
4. [\[\[Conceitos Fundamentais\]\]](#)
5. [\[\[Métodos, Técnicas e Algoritmos\]\]](#)
6. [\[\[Artefatos, Métricas e Protocolos de Avaliação\]\]](#)

O objetivo é permitir que estudantes, pesquisadores e equipes técnicas naveguem pela proposta de forma semelhante a uma **enciclopédia técnica**, conectando cada tema a seus conceitos relacionados.

Por exemplo:

- ao estudar [\[\[Qualidade de Dados\]\]](#), o estudante poderá acessar [\[\[Completude\]\]](#), [\[\[Consistência\]\]](#), [\[\[Validade\]\]](#), [\[\[Unicidade\]\]](#), [\[\[Integridade\]\]](#), [\[\[Atualidade\]\]](#), [\[\[Conformidade\]\]](#), [\[\[Regras de Validação\]\]](#), [\[\[Data Profiling\]\]](#), [\[\[Great Expectations\]\]](#), [\[\[Pandera\]\]](#), [\[\[Deequ\]\]](#) e [\[\[Relatório de Qualidade dos Dados\]\]](#);
- ao estudar [\[\[Proveniência, Linhagem e Rastreabilidade\]\]](#), poderá navegar para [\[\[Data Lineage\]\]](#), [\[\[W3C PROV\]\]](#), [\[\[OpenLineage\]\]](#), [\[\[Grafo de Linhagem\]\]](#), [\[\[Manifesto de Execução\]\]](#), [\[\[Rastreabilidade de Atributos\]\]](#), [\[\[Análise de Impacto\]\]](#) e [\[\[Reprodutibilidade\]\]](#);
- ao estudar [\[\[Representações Analíticas\]\]](#), poderá acessar [\[\[Dados Tabulares\]\]](#), [\[\[Séries Temporais\]\]](#), [\[\[Grafos\]\]](#), [\[\[Grafos Temporais\]\]](#), [\[\[Feature Engineering\]\]](#), [\[\[Métricas de Redes\]\]](#), [\[\[Node2Vec\]\]](#), [\[\[GraphSAGE\]\]](#), [\[\[GAT\]\]](#) e [\[\[Feature Store\]\]](#).

2. Missão do UnespDataLens

A missão do **UnespDataLens** é transformar dados heterogêneos, distribuídos e pouco documentados em **ativos analíticos confiáveis, qualificados, governados, rastreáveis, equitativos e reprodutíveis**, capazes de apoiar:

- [[Análise Exploratória de Dados]];
- [[Indicadores Analíticos]];
- [[Dashboards]];
- [[Modelos Preditivos]];
- [[Modelos Explicáveis]];
- [[Representações em Grafos]];
- [[Grafos Temporais]];
- [[Feature Store]];
- [[Sistemas de Apoio à Decisão]];
- [[Agentes Inteligentes]];
- [[Políticas Públicas Baseadas em Evidências]];
- [[Educação Baseada em Evidências]];
- [[Tomada de Decisão Baseada em Dados]].

3. Definição resumida

O **UnespDataLens** é um framework composto por **módulos técnico-metodológicos, dimensões complementares, artefatos formais, métricas, processos de avaliação e diretrizes de implementação**, orientado à construção de pipelines de Engenharia de Dados Analíticos.

Ele busca responder à seguinte questão:

Como transformar dados brutos, heterogêneos, distribuídos, incompletos, sensíveis, instáveis ou pouco documentados em ativos analíticos confiáveis, rastreáveis, versionados, governados, reprodutíveis e adequados ao uso?

4. Princípios estruturantes

O UnespDataLens é orientado por princípios que atravessam todos os módulos do framework.

4.1 [[Qualidade Multidimensional dos Dados]]

A qualidade dos dados deve ser avaliada por múltiplas dimensões, incluindo [[Completeness]], [[Consistency]], [[Validity]], [[Uniqueness]], [[Integrity]], [[Actuality]], [

], [[Precision]], [[Semantic Coherence]], [[Temporal Stability]] e [[Adequacy to Use]].

4.2 [[Governança de Dados]]

A governança envolve [[Políticas de Dados]], [[Papéis e Responsabilidades]], [[Controle de Acesso]], [[Privacidade]], [[Segurança]], [[LGPD]], [[Classificação de Sensibilidade]], [[Finalidade de Uso]], [[Minimização de Dados]] e [[Conformidade]].

4.3 [[Proveniência, Linhagem e Rastreabilidade]]

Todo ativo analítico deve permitir reconstruir sua origem, transformações, versões, dependências, regras, parâmetros e consumidores. Essa dimensão envolve [[Data Provenance]], [[Data Lineage]], [[Rastreabilidade]], [[Grafo de Linhagem]], [[OpenLineage]], [[W3C PROV]] e [[Análise de Impacto]].

4.4 [[Versionamento e Reprodutibilidade]]

Bases, scripts, regras, configurações, ambientes, modelos, métricas e produtos devem ser versionados. A reprodutibilidade envolve [[Manifesto de Execução]], [[Snapshots]], [[Controle de Versão]], [[Reexecução de Pipeline]], [[Ambiente Computacional]] e [[Pacote de Reprodutibilidade]].

4.5 [[Preparação Analítica Orientada ao Uso]]

A preparação dos dados depende da finalidade. Dados para [[Dashboard]], [[Modelo Preditivo]], [[Análise Causal]], [[Grafo]], [[Feature Store]], [[Indicador]] ou [[Agente Inteligente]] exigem diferentes formas de validação, transformação e documentação.

4.6 [[Equidade, Vieses e Fairness]]

O framework considera riscos de [[Viés de Coleta]], [[Viés de Seleção]], [[Viés de Representação]], [[Viés de Rotulagem]], [[Viés Algorítmico]], [[Desbalanceamento de Classes]], [[Fairness]], [[Representatividade]] e [[Mitigação de Vieses]].

4.7 [[Múltiplas Representações dos Dados]]

Os dados podem ser organizados como [[Dados Tabulares]], [[Dados Temporais]], [[Séries Temporais]], [[Grafos]], [[Grafos Temporais]], [[Redes Heterogêneas]], [[Redes Bipartidas]], [[Feature Matrix]] e [[Feature Store]].

4.8 [[Monitoramento Contínuo dos Ativos]]

Ativos analíticos devem ser monitorados quanto a [[Data Drift]], [[Schema Drift]], [[Feature Drift]], [[Label Drift]], [[Concept Drift]], [[Data Observability]], [[Qualidade ao Longo do Tempo]], [[Uso dos Ativos]] e [[Obsolescência]].

4.9 [[Apoio Inteligente ao Pipeline]]

Agentes inteligentes podem apoiar [[Descoberta de Dados]], [[Documentação Assistida]], [[Explicação de Indicadores]], [[Consulta a Metadados]], [[Análise de Lineage]], [[Recomendação de Features]], [[Interpretação de Alertas]] e [[Apoio à Governança]].

5. Módulos do UnespDataLens

Os módulos do UnespDataLens são organizados em dois grupos:

- [[Pipeline Principal]]
 - [[Módulos Transversais]]
-

5.1 Pipeline Principal

O pipeline principal representa o fluxo técnico-operacional de preparação, qualificação, armazenamento e disponibilização dos dados.

[[Módulo 1 — Fontes e Inventário de Dados]]

O módulo de [[Fontes e Inventário de Dados]] identifica, mapeia, caracteriza, classifica e documenta fontes relevantes para o projeto analítico.

Conceitos relacionados:

- [[Fonte de Dados]]
- [[Inventário de Fontes]]
- [[Sistema de Origem]]
- [[Granularidade]]
- [[Cobertura Temporal]]
- [[Periodicidade]]
- [[Restrição de Acesso]]
- [[Classificação de Sensibilidade]]
- [[Mapa de Bases]]
- [[Dicionário Preliminar]]
- [[Matriz de Relacionamento entre Fontes]]
- [[Mapa de Entidades]]

Artefatos principais:

- [[A1.1 Inventário de Fontes]]
 - [[A1.2 Mapa de Bases]]
 - [[A1.3 Dicionário Preliminar]]
 - [[A1.4 Matriz de Relacionamento]]
 - [[A1.5 Registro de Granularidade]]
 - [[A1.6 Classificação de Sensibilidade]]
 - [[A1.7 Catálogo Preliminar]]
 - [[A1.8 Relatório de Riscos Iniciais]]
 - [[A1.9 Mapa Preliminar de Entidades]]
 - [[A1.10 Registro de Limitações Conhecidas]]
-

[[Módulo 2 — Extração, Ingestão e Armazenamento Bruto]]

O módulo de [[Extração, Ingestão e Armazenamento Bruto]] controla a entrada dos dados no ambiente analítico, preservando sua forma original, logs, snapshots, versões e evidências de ingestão.

Conceitos relacionados:

- [[Extração de Dados]]
- [[Ingestão de Dados]]
- [[Armazenamento Bruto]]
- [[Data Lake]]
- [[Zona Bruta]]
- [[Snapshot]]
- [[Checksum]]
- [[Log de Ingestão]]
- [[Manifesto de Ingestão]]
- [[Pipeline de Ingestão]]
- [[ETL]]
- [[ELT]]

Técnicas e ferramentas:

- [[APIs]]
- [[Conectores]]
- [[Apache NiFi]]
- [[Airflow]]
- [[Prefect]]
- [[Dagster]]
- [[Spark]]
- [[Kafka]]
- [[Object Storage]]
- [[Parquet]]
- [[JSON]]
- [[CSV]]

[[Módulo 3 — Integração e Harmonização]]

O módulo de [[Integração e Harmonização]] combina fontes distintas, resolve conflitos, padroniza estruturas e harmoniza chaves, entidades, atributos, domínios e granularidades.

Conceitos relacionados:

- [[Integração de Dados]]
- [[Harmonização de Dados]]
- [[Chave de Integração]]
- [[Entidade Compartilhada]]
- [[Resolução de Entidades]]
- [[Correspondência de Registros]]
- [[Conflito de Dados]]

- [[Interoperabilidade Semântica]]
- [[Granularidade Compatível]]
- [[Mapa de Equivalência Semântica]]

Técnicas e métodos:

- [[Entity Resolution]]
- [[Record Linkage]]
- [[Schema Matching]]
- [[String Similarity]]
- [[Levenshtein]]
- [[Jaro-Winkler]]
- [[Blocking]]
- [[Fuzzy Matching]]
- [[Mapeamento Semântico]]

[[Módulo 4 — Transformação, Limpeza e Enriquecimento]]

O módulo de [[Transformação, Limpeza e Enriquecimento]] aplica regras de tratamento, padronização, correção, derivação, enriquecimento e preparação dos dados para análise.

Conceitos relacionados:

- [[Transformação de Dados]]
- [[Limpeza de Dados]]
- [[Enriquecimento de Dados]]
- [[Tratamento de Valores Ausentes]]
- [[Tratamento de Outliers]]
- [[Normalização]]
- [[Padronização]]
- [[Deduplicação]]
- [[Recodificação]]
- [[Atributos Derivados]]
- [[Regras de Transformação]]

Técnicas e ferramentas:

- [[pandas]]
- [[PySpark]]
- [[SQL]]
- [[dbt]]
- [[DuckDB]]
- [[Data Profiling]]
- [[Imputação]]
- [[Winsorização]]
- [[One-Hot Encoding]]
- [[Feature Scaling]]

[[Módulo 5 — Qualidade e Validação de Dados]]

O módulo de [[Qualidade e Validação de Dados]] avalia se os dados atendem a critérios mínimos de completude, consistência, validade, unicidade, integridade, atualidade, conformidade e adequação ao uso.

Conceitos relacionados:

- [[Qualidade de Dados]]
- [[Completude]]
- [[Consistência]]
- [[Validade]]
- [[Unicidade]]
- [[Integridade Referencial]]
- [[Atualidade]]
- [[Conformidade]]
- [[Acurácia]]
- [[Adequação ao Uso]]
- [[Data Quality Score]]

Técnicas e ferramentas:

- [[Data Validation]]
- [[Schema Validation]]
- [[Data Contracts]]
- [[Great Expectations]]
- [[Pandera]]
- [[Deequ]]
- [[Soda Core]]
- [[dbt Tests]]
- [[ydata-profiling]]
- [[Regras de Domínio]]

[[Módulo 6 — Desbalanceamento, Vieses e Equidade]]

O módulo de [[Desbalanceamento, Vieses e Equidade]] identifica, mensura, documenta e, quando necessário, mitiga desbalanceamentos, vieses e desigualdades nos dados e nas representações analíticas.

Conceitos relacionados:

- [[Desbalanceamento de Classes]]
- [[Imbalance Ratio]]
- [[Viés de Coleta]]
- [[Viés de Seleção]]
- [[Viés Histórico]]
- [[Viés de Representação]]
- [[Viés de Rotulagem]]
- [[Fairness]]

- [[Equidade Algorítmica]]
- [[Atributos Sensíveis]]
- [[Proxy de Atributo Sensível]]

Métricas e técnicas:

- [[Statistical Parity Difference]]
- [[Disparate Impact]]
- [[Equal Opportunity Difference]]
- [[Average Odds Difference]]
- [[False Positive Rate]]
- [[False Negative Rate]]
- [[SMOTE]]
- [[ADASYN]]
- [[Random Oversampling]]
- [[Random Undersampling]]
- [[Class Weights]]
- [[Threshold Moving]]

[[Módulo 7 — Armazenamento Analítico]]

O módulo de [[Armazenamento Analítico]] organiza, persiste e disponibiliza internamente datasets tratados, integrados, validados e curados em estruturas adequadas à análise.

Conceitos relacionados:

- [[Data Warehouse]]
- [[Data Lake]]
- [[Lakehouse]]
- [[Data Mart]]
- [[Modelo Dimensional]]
- [[Tabela Fato]]
- [[Tabela Dimensão]]
- [[Schema Estrela]]
- [[Schema Floco de Neve]]
- [[Zona Curada]]
- [[Zona de Consumo]]
- [[View Materializada]]

Tecnologias:

- [[PostgreSQL]]
- [[SQL Server]]
- [[BigQuery]]
- [[Snowflake]]
- [[Redshift]]
- [[Databricks]]
- [[Delta Lake]]
- [[Apache Iceberg]]
- [[Apache Hudi]]

- [[ClickHouse]]
 - [[DuckDB]]
 - [[Trino]]
-

[[Módulo 8 — Disponibilização e Consumo Analítico]]

O módulo de [[Disponibilização e Consumo Analítico]] transforma ativos analíticos armazenados em produtos consumíveis por pessoas, sistemas, modelos, dashboards, APIs e processos decisórios.

Conceitos relacionados:

- [[Produto de Dados]]
- [[Dashboard]]
- [[API de Dados]]
- [[Dataset Curado]]
- [[Relatório Analítico]]
- [[Indicador]]
- [[Data Product]]
- [[Camada de Consumo]]
- [[Consumo Analítico]]
- [[Matriz de Acesso]]
- [[Registro de Uso]]
- [[Feedback do Usuário]]

Ferramentas:

- [[Power BI]]
 - [[Metabase]]
 - [[Superset]]
 - [[Streamlit]]
 - [[Dash]]
 - [[FastAPI]]
 - [[APIs REST]]
 - [[GraphQL]]
 - [[Data Catalog]]
-

5.2 Módulos Transversais

Os módulos transversais atuam sobre todo o ciclo de vida dos dados.

[[Módulo 9 — Metadados, Catálogo e Semântica dos Dados]]

Conceitos relacionados:

- [[Metadados]]
- [[Catálogo de Dados]]
- [[Dicionário de Dados]]

- [[Glossário de Dados]]
 - [[Modelo Semântico]]
 - [[Taxonomia]]
 - [[Vocabulário Controlado]]
 - [[Data Discoverability]]
 - [[Qualidade de Metadados]]
 - [[Interoperabilidade Semântica]]
-

[[Módulo 10 — Governança, Segurança, Privacidade e Conformidade]]

Conceitos relacionados:

- [[Governança de Dados]]
 - [[Segurança de Dados]]
 - [[Privacidade]]
 - [[LGPD]]
 - [[Controle de Acesso]]
 - [[RBAC]]
 - [[Anonimização]]
 - [[Pseudonimização]]
 - [[Minimização de Dados]]
 - [[Finalidade de Uso]]
 - [[Classificação de Sensibilidade]]
 - [[Conformidade]]
-

[[Módulo 11 — Proveniência, Linhagem e Rastreabilidade]]

Conceitos relacionados:

- [[Proveniência]]
 - [[Data Lineage]]
 - [[Rastreabilidade]]
 - [[W3C PROV]]
 - [[OpenLineage]]
 - [[Grafo de Linhagem]]
 - [[Rastreabilidade de Atributos]]
 - [[Análise de Impacto]]
 - [[Trilha de Auditoria]]
 - [[Manifesto de Linhagem]]
-

[[Módulo 12 — Versionamento e Reprodutibilidade]]

Conceitos relacionados:

- [[Versionamento de Dados]]

- [[Versionamento de Código]]
 - [[Versionamento de Schema]]
 - [[Reprodutibilidade]]
 - [[Reexecução]]
 - [[Snapshot]]
 - [[Changelog]]
 - [[Manifesto de Execução]]
 - [[Ambiente Computacional]]
 - [[DVC]]
 - [[MLflow]]
 - [[LakeFS]]
 - [[Git]]
-

[[Módulo 13 — Representações Analíticas: Tabular, Temporal e Grafos]]

Conceitos relacionados:

- [[Representação Tabular]]
 - [[Representação Temporal]]
 - [[Série Temporal]]
 - [[Janela Temporal]]
 - [[Evento]]
 - [[Grafo]]
 - [[Grafo Temporal]]
 - [[Grafo Heterogêneo]]
 - [[Grafo Bipartido]]
 - [[Métrica de Centralidade]]
 - [[Métrica de Redes]]
 - [[NetworkX]]
 - [[Neo4j]]
 - [[PyTorch Geometric]]
 - [[DGL]]
-

[[Módulo 14 — Feature Engineering e Feature Store]]

Conceitos relacionados:

- [[Feature Engineering]]
- [[Feature Store]]
- [[Feature Set]]
- [[Feature Matrix]]
- [[Atributo Derivado]]
- [[Feature Temporal]]
- [[Feature Relacional]]
- [[Feature de Grafo]]
- [[Feature Drift]]

- [[Data Leakage]]
 - [[Feast]]
 - [[Tecton]]
 - [[Hopsworks]]
-

[[Módulo 15 — Monitoramento, Drift e Evolução dos Ativos]]

Conceitos relacionados:

- [[Monitoramento de Dados]]
 - [[Data Drift]]
 - [[Schema Drift]]
 - [[Feature Drift]]
 - [[Label Drift]]
 - [[Concept Drift]]
 - [[Data Observability]]
 - [[Alerta de Qualidade]]
 - [[Baseline]]
 - [[Evidently AI]]
 - [[WhyLabs]]
 - [[Prometheus]]
 - [[Grafana]]
-

[[Módulo 16 — Agentes Inteligentes de Apoio ao Pipeline]]

Conceitos relacionados:

- [[Agentes Inteligentes]]
 - [[LLM]]
 - [[Busca Semântica]]
 - [[Embeddings]]
 - [[RAG]]
 - [[Base Vetorial]]
 - [[Agente de Descoberta de Dados]]
 - [[Agente de Qualidade]]
 - [[Agente de Lineage]]
 - [[Agente de Governança]]
 - [[Agente de Feature Engineering]]
 - [[Agente de Monitoramento]]
 - [[Human-in-the-loop]]
-

6. Dimensões Complementares

As [[Dimensões Complementares]] representam capacidades transversais que ampliam a maturidade do UnespDataLens.

[[Data Overload]]

Trata da sobrecarga gerada pelo excesso de fontes, atributos, datasets, dashboards, indicadores, APIs, features e produtos analíticos.

Links relacionados:

- [[Sobrecarga de Dados]]
 - [[Curadoria de Ativos]]
 - [[Redundância de Ativos]]
 - [[Produtos Obsoletos]]
 - [[Reutilização de Dados]]
 - [[Priorização de Ativos]]
-

[[Data Silos]]

Trata do isolamento de dados em sistemas, áreas, bases, planilhas, plataformas ou repositórios distintos.

Links relacionados:

- [[Silos de Dados]]
 - [[Integração de Dados]]
 - [[Interoperabilidade]]
 - [[Mapa de Silos]]
 - [[Entidades Compartilhadas]]
 - [[Chaves de Integração]]
-

[[Data Debt]]

Trata do acúmulo de passivos técnicos, metodológicos, semânticos e organizacionais nos dados, pipelines e produtos.

Links relacionados:

- [[Dívida de Dados]]
 - [[Dívida Técnica]]
 - [[Ativos sem Responsável]]
 - [[Regras não Documentadas]]
 - [[Produtos Obsoletos]]
 - [[Plano de Redução da Dívida]]
-

[[Data Observability]]

Trata da capacidade de observar, diagnosticar e explicar o comportamento dos dados, pipelines e produtos analíticos.

Links relacionados:

- [[Observabilidade de Dados]]
 - [[Logs Estruturados]]
 - [[Métricas Operacionais]]
 - [[Painel de Saúde dos Dados]]
 - [[Registro de Incidentes]]
 - [[Análise de Causa Raiz]]
 - [[SLA de Dados]]
-

[[Schema Drift]]

Trata das mudanças estruturais que afetam atributos, tipos, domínios, chaves, categorias e granularidades.

Links relacionados:

- [[Deriva de Esquema]]
 - [[Schema Validation]]
 - [[Versionamento de Schema]]
 - [[Contrato de Dados]]
 - [[Alerta de Schema Drift]]
 - [[Compatibilidade Retroativa]]
-

[[Data Contracts]]

Trata dos acordos formais entre produtores e consumidores de dados.

Links relacionados:

- [[Contrato de Dados]]
 - [[Produtor de Dados]]
 - [[Consumidor de Dados]]
 - [[SLA de Dados]]
 - [[Violação Contratual]]
 - [[Schema Contratado]]
 - [[Regras de Qualidade Contratadas]]
-

[[Qualidade de Metadados]]

Trata da completude, precisão, consistência, atualidade, padronização, rastreabilidade e utilidade dos metadados.

Links relacionados:

- [[Metadados Mínimos]]
- [[Índice de Qualidade de Metadados]]

- [\[\[Glossário\]\]](#)
 - [\[\[Dicionário de Dados\]\]](#)
 - [\[\[Ficha do Ativo\]\]](#)
 - [\[\[Curadoria de Metadados\]\]](#)
-

[[Data Discoverability]]

Trata da capacidade de localizar, compreender, avaliar e reutilizar ativos de dados.

Links relacionados:

- [\[\[Descoberta de Dados\]\]](#)
 - [\[\[Catálogo de Ativos\]\]](#)
 - [\[\[Busca Semântica\]\]](#)
 - [\[\[Índice de Busca\]\]](#)
 - [\[\[Tags\]\]](#)
 - [\[\[Ficha de Descoberta\]\]](#)
 - [\[\[Recomendação de Ativos\]\]](#)
-

[[Data Minimization]]

Trata da coleta, tratamento e disponibilização apenas dos dados necessários para uma finalidade explícita.

Links relacionados:

- [\[\[Minimização de Dados\]\]](#)
 - [\[\[Finalidade de Uso\]\]](#)
 - [\[\[Granularidade Mínima\]\]](#)
 - [\[\[Pseudonimização\]\]](#)
 - [\[\[Anonimização\]\]](#)
 - [\[\[Retenção de Dados\]\]](#)
 - [\[\[Acesso por Finalidade\]\]](#)
-

[[Label Quality]]

Trata da qualidade dos rótulos, variáveis-alvo, classes, categorias e desfechos.

Links relacionados:

- [\[\[Qualidade de Rótulos\]\]](#)
- [\[\[Variável-Alvo\]\]](#)
- [\[\[Rótulo de Evasão\]\]](#)
- [\[\[Label Drift\]\]](#)
- [\[\[Ruído de Rótulo\]\]](#)
- [\[\[Balanceamento de Classes\]\]](#)
- [\[\[Regra de Rotulagem\]\]](#)

- [\[\[Manifesto de Construção do Rótulo\]\]](#)
-

[[Data Uncertainty]]

Trata da incerteza associada aos dados, atributos, rótulos, features, indicadores, modelos e produtos.

Links relacionados:

- [\[\[Incerteza nos Dados\]\]](#)
 - [\[\[Valores Ausentes\]\]](#)
 - [\[\[Valores Imputados\]\]](#)
 - [\[\[Intervalo de Confiança\]\]](#)
 - [\[\[Confiabilidade da Fonte\]\]](#)
 - [\[\[Incerteza de Integração\]\]](#)
 - [\[\[Incerteza de Rótulo\]\]](#)
 - [\[\[Limitações Interpretativas\]\]](#)
-

[[Interoperabilidade Semântica]]

Trata da compatibilidade de significado entre conceitos, atributos, categorias, indicadores e fontes.

Links relacionados:

- [\[\[Glossário Semântico\]\]](#)
 - [\[\[Vocabulário Controlado\]\]](#)
 - [\[\[Taxonomia\]\]](#)
 - [\[\[Mapa de Equivalência Semântica\]\]](#)
 - [\[\[Conflito Semântico\]\]](#)
 - [\[\[Camada Semântica Analítica\]\]](#)
-

[[DataOps]]

Trata da automação, orquestração, versionamento, validação, monitoramento e melhoria contínua dos pipelines de dados.

Links relacionados:

- [\[\[Orquestração de Pipelines\]\]](#)
 - [\[\[Workflow\]\]](#)
 - [\[\[DAG\]\]](#)
 - [\[\[Testes Automatizados de Dados\]\]](#)
 - [\[\[Logs de Execução\]\]](#)
 - [\[\[Manifesto DataOps\]\]](#)
 - [\[\[Pipeline Automatizado\]\]](#)
 - [\[\[Gestão de Incidentes\]\]](#)
-

[[MLOps]]

Trata da gestão do ciclo de vida de modelos de aprendizagem de máquina.

Links relacionados:

- [[Registro de Experimentos]]
 - [[Model Registry]]
 - [[Versionamento de Modelos]]
 - [[Dataset de Treinamento]]
 - [[Feature Set]]
 - [[Model Card]]
 - [[Explicabilidade]]
 - [[Fairness do Modelo]]
 - [[Monitoramento de Modelos]]
 - [[Retreinamento]]
 - [[Descontinuação de Modelo]]
-

7. Conceitos Fundamentais

Esta seção reúne os conceitos mais importantes para compreender o UnespDataLens.

Engenharia de Dados

- [[Engenharia de Dados]]
- [[Pipeline de Dados]]
- [[ETL]]
- [[ELT]]
- [[Data Lake]]
- [[Data Warehouse]]
- [[Lakehouse]]
- [[Data Mart]]
- [[Data Product]]
- [[Data Mesh]]

Qualidade e Governança

- [[Qualidade de Dados]]
- [[Governança de Dados]]
- [[Data Governance]]
- [[Privacidade]]
- [[Segurança]]
- [[LGPD]]
- [[Data Steward]]
- [[Data Owner]]
- [[Data Custodian]]
- [[Data Contract]]

Ciência de Dados e IA

- [[Ciência de Dados]]
- [[Mineração de Dados]]
- [[KDD]]
- [[Aprendizagem de Máquina]]
- [[Modelo Preditivo]]
- [[Modelo Explicável]]
- [[XAI]]
- [[SHAP]]
- [[LIME]]
- [[Fairness]]
- [[MLOps]]

Representações Analíticas

- [[Dados Tabulares]]
 - [[Dados Temporais]]
 - [[Séries Temporais]]
 - [[Eventos]]
 - [[Grafos]]
 - [[Grafos Temporais]]
 - [[Redes]]
 - [[Métricas Relacionais]]
 - [[Feature Engineering]]
-

8. Métodos, Técnicas e Algoritmos

Qualidade e Validação

- [[Data Profiling]]
- [[Data Validation]]
- [[Schema Validation]]
- [[Rule-based Validation]]
- [[Outlier Detection]]
- [[Anomaly Detection]]
- [[PSI]]
- [[KS Statistic]]
- [[Great Expectations]]
- [[Pandera]]
- [[Deequ]]
- [[Soda Core]]

Integração e Harmonização

- [[Entity Resolution]]
- [[Record Linkage]]
- [[Schema Matching]]
- [[Fuzzy Matching]]
- [[String Similarity]]

- [[Levenshtein]]
- [[Jaro-Winkler]]
- [[Blocking]]
- [[Mapeamento Semântico]]

Desbalanceamento e Fairness

- [[SMOTE]]
- [[ADASYN]]
- [[Random Oversampling]]
- [[Random Undersampling]]
- [[Tomek Links]]
- [[Class Weights]]
- [[Threshold Moving]]
- [[Statistical Parity Difference]]
- [[Disparate Impact]]
- [[Equal Opportunity Difference]]
- [[Average Odds Difference]]

Grafos e Representações Relacionais

- [[Grafo]]
- [[Grafo Bipartido]]
- [[Grafo Heterogêneo]]
- [[Grafo Temporal]]
- [[Centralidade de Grau]]
- [[Centralidade de Intermediação]]
- [[Centralidade de Proximidade]]
- [[PageRank]]
- [[Componentes Conectados]]
- [[Comunidades]]
- [[Node2Vec]]
- [[GraphSAGE]]
- [[GCN]]
- [[GAT]]

MLOps e Modelagem

- [[Registro de Experimentos]]
- [[Validação Cruzada]]
- [[Validação Temporal]]
- [[Model Registry]]
- [[Model Card]]
- [[Feature Store]]
- [[Data Leakage]]
- [[Data Drift]]
- [[Feature Drift]]
- [[Concept Drift]]
- [[Retreinamento de Modelos]]

9. Artefatos Centrais

O UnespDataLens produz artefatos técnicos, metodológicos e computacionais.

Artefatos de entrada e inventário

- [[Inventário de Fontes]]
- [[Mapa de Bases]]
- [[Dicionário Preliminar]]
- [[Mapa de Entidades]]
- [[Classificação de Sensibilidade]]
- [[Registro de Limitações]]

Artefatos de qualidade e validação

- [[Relatório de Qualidade]]
- [[Catálogo de Regras de Validação]]
- [[Registro de Não Conformidades]]
- [[Matriz de Severidade]]
- [[Selo de Qualidade]]

Artefatos de governança

- [[Política de Governança]]
- [[Matriz de Papéis e Responsabilidades]]
- [[Matriz de Acesso]]
- [[Registro de Finalidade de Uso]]
- [[Registro de Conformidade]]
- [[Plano de Retenção e Descarte]]

Artefatos de linhagem e reprodutibilidade

- [[Grafo de Linhagem]]
- [[Manifesto de Execução]]
- [[Registro de Versões]]
- [[Pacote de Reprodutibilidade]]
- [[Changelog de Dados]]
- [[Relatório de Comparação de Versões]]

Artefatos de representação e modelagem

- [[Feature Store]]
- [[Catálogo de Features]]
- [[Matriz de Features]]
- [[Representação Temporal]]
- [[Modelo de Grafo]]
- [[Lista de Nós e Arestas]]
- [[Model Card]]
- [[Registro de Experimentos]]

Artefatos de consumo

- [[Dataset Curado]]
 - [[Dashboard]]
 - [[API de Dados]]
 - [[Relatório Analítico]]
 - [[Produto de Dados]]
 - [[Registro de Uso]]
 - [[Feedback do Usuário]]
-

10. Problemas Tratados pelo Framework

O UnespDataLens foi concebido para enfrentar problemas recorrentes em ecossistemas de dados.

Problemas de dados

- [[Dados Ausentes]]
- [[Dados Duplicados]]
- [[Dados Inconsistentes]]
- [[Dados Obsoletos]]
- [[Dados Sensíveis]]
- [[Dados Sem Responsável]]
- [[Dados Sem Documentação]]
- [[Dados com Baixa Qualidade]]
- [[Dados com Baixa Representatividade]]

Problemas de integração

- [[Silos de Dados]]
- [[Chaves Incompatíveis]]
- [[Granularidade Incompatível]]
- [[Conflitos Semânticos]]
- [[Categorias Divergentes]]
- [[Schema Drift]]
- [[Data Contracts Ausentes]]

Problemas analíticos

- [[Data Overload]]
- [[Data Debt]]
- [[Label Quality]]
- [[Data Uncertainty]]
- [[Data Leakage]]
- [[Desbalanceamento de Classes]]
- [[Viés Algorítmico]]
- [[Baixa Reprodutibilidade]]
- [[Modelo Obsoleto]]

Problemas operacionais

- [[Pipeline Manual]]
 - [[Falha Silenciosa]]
 - [[Ausência de Logs]]
 - [[Ausência de Monitoramento]]
 - [[Ausência de Versionamento]]
 - [[Baixa Observabilidade]]
 - [[Dificuldade de Auditoria]]
-

11. Aplicações

O UnespDataLens pode ser instanciado em diferentes domínios.

[[Educação]]

Aplicações possíveis:

- [[Evasão Escolar]]
- [[Permanência Estudantil]]
- [[Desempenho Acadêmico]]
- [[Engajamento em AVA]]
- [[Perfil do Ingressante]]
- [[Indicadores Educacionais]]
- [[Mineração de Dados Educacionais]]
- [[Learning Analytics]]
- [[EdmLens]]

[[Políticas Públicas]]

Aplicações possíveis:

- [[Indicadores Territoriais]]
- [[Vulnerabilidade Social]]
- [[Saúde Pública]]
- [[Assistência Social]]
- [[Educação Municipal]]
- [[Gestão Pública]]
- [[Atendimento ao Cidadão]]
- [[Avaliação de Programas]]

[[Saúde]]

Aplicações possíveis:

- [[Risco Clínico]]
- [[Atendimentos]]
- [[Eventos em Saúde]]
- [[Indicadores Epidemiológicos]]
- [[Integração de Bases de Saúde]]

- [[Dados Sensíveis]]

[[Trabalho e Organizações]]

Aplicações possíveis:

- [[Relações de Trabalho]]
 - [[Acidentes de Trabalho]]
 - [[Turnover]]
 - [[Saúde e Segurança do Trabalho]]
 - [[Indicadores Organizacionais]]
 - [[Grafos de Relações Trabalhistas]]
-

12. Relação entre UnespDataLens e EdmLens

A [[EdmLens]] pode ser compreendida como uma **especialização educacional** do [[UnespDataLens]].

Enquanto o UnespDataLens define um framework geral de Engenharia de Dados Analíticos aplicável a múltiplos domínios, a EdmLens instancia esse framework no domínio educacional, com foco em:

- [[Dados Educacionais]]
- [[Mineração de Dados Educacionais]]
- [[Learning Analytics]]
- [[Evasão]]
- [[Desempenho Acadêmico]]
- [[Permanência Estudantil]]
- [[AVA]]
- [[Indicadores Educacionais]]
- [[Modelos Preditivos Educacionais]]
- [[Fairness em Educação]]
- [[Grafos Educacionais]]

Assim, a EdmLens permite validar o UnespDataLens em um domínio real, complexo, sensível e altamente relevante.

13. Trilhas de Estudo para Alunos

Trilha 1 — Fundamentos

1. [[Engenharia de Dados]]
2. [[Pipeline de Dados]]
3. [[ETL]]
4. [[ELT]]
5. [[Qualidade de Dados]]
6. [[Governança de Dados]]
7. [[Metadados]]
8. [[Data Lineage]]
9. [[Reprodutibilidade]]

Trilha 2 — Implementação do Pipeline

1. [[Módulo 1 — Fontes e Inventário de Dados]]
2. [[Módulo 2 — Extração, Ingestão e Armazenamento Bruto]]
3. [[Módulo 3 — Integração e Harmonização]]
4. [[Módulo 4 — Transformação, Limpeza e Enriquecimento]]
5. [[Módulo 5 — Qualidade e Validação de Dados]]
6. [[Módulo 7 — Armazenamento Analítico]]
7. [[Módulo 8 — Disponibilização e Consumo Analítico]]

Trilha 3 — Governança, Rastreabilidade e Reprodutibilidade

1. [[Módulo 9 — Metadados, Catálogo e Semântica dos Dados]]
2. [[Módulo 10 — Governança, Segurança, Privacidade e Conformidade]]
3. [[Módulo 11 — Proveniência, Linhagem e Rastreabilidade]]
4. [[Módulo 12 — Versionamento e Reprodutibilidade]]
5. [[Data Contracts]]
6. [[Data Observability]]
7. [[DataOps]]

Trilha 4 — Modelagem, IA e Grafos

1. [[Módulo 13 — Representações Analíticas: Tabular, Temporal e Grafos]]
2. [[Módulo 14 — Feature Engineering e Feature Store]]
3. [[MLOps]]
4. [[Grafos]]
5. [[Grafos Temporais]]
6. [[Métricas de Redes]]
7. [[Modelos Preditivos]]
8. [[Explicabilidade]]
9. [[Fairness]]

Trilha 5 — Dimensões Complementares

1. [[Data Overload]]
 2. [[Data Silos]]
 3. [[Data Debt]]
 4. [[Data Observability]]
 5. [[Schema Drift]]
 6. [[Data Contracts]]
 7. [[Qualidade de Metadados]]
 8. [[Data Discoverability]]
 9. [[Data Minimization]]
 10. [[Label Quality]]
 11. [[Data Uncertainty]]
 12. [[Interoperabilidade Semântica]]
 13. [[DataOps]]
 14. [[MLOps]]
-

14. Modelo de página para cada verbete da wiki

Cada conceito, módulo, técnica, métrica ou artefato deve seguir o mesmo padrão de documentação.

Nome do Verbetes

1. Definição

Explique o conceito de forma clara e objetiva.

2. Relação com o UnespDataLens

Explique em quais módulos, dimensões ou processos o conceito aparece.

3. Problema que resolve

Explique qual lacuna, risco ou desafio o conceito ajuda a enfrentar.

4. Como aplicar

Descreva procedimentos, métodos, etapas ou boas práticas.

5. Técnicas, métodos ou algoritmos relacionados

Liste técnicas, métodos, ferramentas ou algoritmos conectados.

6. Métricas associadas

Liste métricas que podem avaliar o conceito.

7. Artefatos relacionados

Liste documentos, tabelas, relatórios, modelos ou registros produzidos.

8. Exemplo no domínio educacional

Apresente um exemplo aplicado à EdmLens ou a dados educacionais.

9. Exemplo em políticas públicas

Apresente um exemplo em dados públicos, sociais, territoriais ou institucionais.

10. Links relacionados

- [[Conceito relacionado 1]]
- [[Conceito relacionado 2]]
- [[Módulo relacionado]]
- [[Dimensão complementar]]

15. Primeiros verbetes recomendados

Para iniciar a construção da wiki, recomenda-se criar inicialmente os seguintes verbetes:

1. [[UnespDataLens]]
2. [[Engenharia de Dados Analíticos]]
3. [[Pipeline Principal]]
4. [[Módulos Transversais]]
5. [[Dimensões Complementares]]
6. [[Fonte de Dados]]
7. [[Inventário de Fontes]]
8. [[ETL]]
9. [[ELT]]
10. [[Qualidade de Dados]]
11. [[Governança de Dados]]
12. [[Metadados]]
13. [[Catálogo de Dados]]
14. [[Data Lineage]]
15. [[Versionamento]]
16. [[Reprodutibilidade]]
17. [[Dados Tabulares]]
18. [[Dados Temporais]]
19. [[Grafos]]
20. [[Feature Engineering]]
21. [[Feature Store]]
22. [[Data Drift]]
23. [[Schema Drift]]
24. [[Data Observability]]
25. [[Data Contracts]]
26. [[DataOps]]
27. [[MLOps]]
28. [[Agentes Inteligentes]]
29. [[Fairness]]
30. [[EdmLens]]

16. Síntese

Esta wiki organiza o **UnespDataLens** como um ambiente navegável de estudo, pesquisa, documentação e implementação. Sua finalidade é permitir que estudantes e pesquisadores compreendam o framework não apenas como uma sequência de módulos, mas como um ecossistema conceitual interligado, composto por dados, processos, artefatos, métricas, métodos, técnicas, problemas e aplicações.

Ao navegar pelos links, o aluno poderá compreender como cada conceito se conecta aos módulos do framework, quais problemas resolve, quais artefatos produz, quais métricas utiliza e como pode ser aplicado em projetos reais de Engenharia de Dados Analíticos.